

基于注意力机制的关键脑电电极与频段探索

人工智能课程大作业

2026 年 6 月 14 日

摘要

脑电 (EEG) 情绪识别是人工智能在脑机接口和人机交互领域的重要应用。本文基于 SEED 数据集, 提出了一种轻量级双注意力神经网络模型, 通过通道注意力和频段注意力机制, 系统地探索了不同大脑区域和频率成分对情绪识别的贡献。采用留一被试交叉验证 (Leave-One-Subject-Out, LOSO) 评估方法, 模型在 12 名被试上取得了 $81.22\% \pm 6.20\%$ 的平均准确率。消融实验表明, 双注意力机制相比纯 MLP 基线提升了约 2.6 个百分点, 且标准差最小, 验证了注意力机制在跨被试泛化中的有效性。关键电极分析发现, 前额叶 (Fp1, AF3, F1) 和枕叶 (POz, O1) 区域对情绪识别贡献最大, 这与神经科学中情绪处理的前额-枕叶网络一致。频段分析表明, β 和 γ 频段的注意力权重最高, 提示高频脑电成分在情绪识别中具有重要作用。

1 研究背景

情绪识别是人工智能领域的重要研究方向, 在人机交互、智能健康监测、辅助驾驶和心理健康评估等场景中具有广泛应用前景。传统的情绪识别方法主要依赖于面部表情、语音语调和文本分析等外显信号, 但这些信号容易受到主观意志的控制, 难以反映真实的情绪状态。相比之下, 脑电信号 (Electroencephalogram, EEG) 作为一种直接测量大脑电活动的生理信号, 具有客观性强、时间分辨率高等优势, 能够更真实地反映个体的情绪状态。

近年来, 随着深度学习技术的快速发展, 基于脑电的情绪识别研究取得了显著进展。Zheng 和 Lu [1] 首次发布了 SEED (SJTU Emotion EEG Dataset) 数据集, 并利用深度神经网络 (DNN) 探索了不同频段和电极通道对情绪识别的贡献, 在 subject-dependent 设定下取得了约 87% 的分类准确率。然而, 脑电信号存在显著的个体差异, 同一模型在不同被试之间的泛化能力通常较弱, 跨被试 (cross-subject) 情绪识别仍然是一个具有挑战性的问题。

注意力机制 (Attention Mechanism) 作为深度学习中的一项重要技术, 已经在自然语言处理和计算机视觉等领域取得了巨大成功。在脑电分析中, 注意力机制可以自适应地学习不同电极通道和频率成分的重要性权重, 从而揭示与情绪相关的关键脑区和频段。SE-Net [2] 提出的 Squeeze-and-Excitation 结构为本文的注意力模块设计提供了重要参考。

本文的研究目标包括：(1) 设计一种轻量级双注意力模型，在跨被试设定下实现有效的情绪识别；(2) 通过注意力权重分析，识别对情绪识别最关键的大脑电极和频率成分；(3) 通过消融实验验证各组件的有效性。

2 数据集说明与数据处理

2.1 SEED 数据集概述

SEED (SJTU Emotion EEG Dataset) 数据集由上海交通大学 BCMI 实验室发布 [1]，是目前脑电情绪识别领域广泛使用的公开数据集之一。该数据集包含 15 名被试（7 名男性，8 名女性，平均年龄约 23.27 岁）在观看情绪诱发电影片段时采集的 62 通道脑电信号。

实验采用 15 段精心挑选的中国电影片段作为情绪刺激材料，每段约 4 分钟，其中积极 (Positive)、消极 (Negative) 和中性 (Neutral) 情绪片段各 5 段。每位被试重复实验 3 次，每次间隔约一周，以评估信号的稳定性。同时，数据集还记录了 12 名被试的眼动数据，为多模态研究提供了可能。

2.2 特征提取

原始脑电信号经过以下预处理和特征提取步骤：

1. 降采样至 200 Hz，带通滤波至 0–75 Hz 范围。
2. 使用 1 秒滑动窗口（无重叠）对信号进行分段。
3. 对每个窗口提取 5 个频段的微分熵 (Differential Entropy, DE) 特征：
 - delta (δ , 1–4 Hz)
 - theta (θ , 4–8 Hz)
 - alpha (α , 8–14 Hz)
 - beta (β , 14–31 Hz)
 - gamma (γ , 31–50 Hz)
4. 每个样本的维度为 62 通道 $\times$ 5 频段 = 310 维。

本实验直接使用数据集提供的预提取特征 (.npz 格式)，数据布局为频段优先 (band-major)：前 62 维对应 delta 频段的全通道值，随后依次为 theta、alpha、beta、gamma。

2.3 数据预处理

跨被试脑电情绪识别的核心挑战在于脑电信号存在显著的个体差异——不同被试的电极阻抗、头型、精神状态等因素导致信号的基线水平和方差差异很大。如果直接使用全局标准化，模型会倾向于学习”识别被试身份”而非”识别情绪状态”。

为解决这一问题，本文采用**逐被试 z-score 标准化**：

$$X'_s = \frac{X_s - \mu_s}{\sigma_s} \quad (1)$$

其中 X_s 为被试 s 的原始特征矩阵， μ_s 和 σ_s 分别为该被试 310 维特征各自的均值和标准差。该操作在数据加载阶段一次性完成，每个被试独立标准化，消除个体基线偏移的同时保留情绪相关的相对模式。

实验使用 12 名具有 EEG 数据的被试（被试 ID: 1–5, 8–14），每名被试包含 3 次会话 $\times$ 842 个样本 = 2526 个样本，共计 30,312 个样本。三类标签（积极/消极/中性）在每名被试内均匀分布。

2.4 数据划分

本文采用留一被试交叉验证（Leave-One-Subject-Out, LOSO）进行跨被试评估：

1. 共进行 12 折交叉验证，每折将 1 名被试的全部数据作为测试集（2526 样本）。
2. 其余 11 名被试的数据作为训练集（约 27,786 样本）。
3. 最终以 12 折的平均准确率和标准差作为评估指标。

3 模型方法

3.1 模型总体架构

本文提出的脑电双注意力模型（EEG Dual-Attention Model）由三个核心组件构成：通道注意力模块（Channel Attention）、频段注意力模块（Frequency Band Attention）和轻量级 MLP 分类器。模型结构如图 1 所示。

输入: $(B, 310)$ EEG 特征向量	
通道视图 $(B, 62, 5)$ Pool over bands $\rightarrow (B, 62)$ MLP(62 $\rightarrow$ 15 $\rightarrow$ 62) + Sigmoid 通道注意力 $\mathbf{a}_c \in (0, 1)^{62}$	频段视图 $(B, 5, 62)$ Pool over channels $\rightarrow (B, 5)$ MLP(5 $\rightarrow$ 10 $\rightarrow$ 5) + Sigmoid 频段注意力 $\mathbf{a}_f \in (0, 1)^5$
加权: $\tilde{X} = X \odot (1 + \alpha \mathbf{a}_c + \beta \mathbf{a}_f)$, 其中 α, β 可学习, 初始为 0	
Flatten $\rightarrow (B, 310) \rightarrow$ MLP(310 $\rightarrow$ 64 $\rightarrow$ 32 $\rightarrow$ 3)	
输出: $(B, 3)$ 三类情绪 logits	

图 1: 双注意力模型架构示意

3.2 双视图构建

输入的 310 维特征采用频段优先(band-major)布局: $[\delta_1 \dots \delta_{62}, \theta_1 \dots \theta_{62}, \alpha_1 \dots \alpha_{62}, \beta_1 \dots \beta_{62}, \gamma_1 \dots \gamma_{62}]$ 为正确提取通道和频段两个维度的特征, 首先将输入 reshape 为频段视图 $\mathbf{X}_{\text{freq}} \in \mathbb{R}^{B \times 5 \times 62}$ (匹配 band-major 内存布局), 再通过 transpose 获得通道视图 $\mathbf{X}_{\text{ch}} = \mathbf{X}_{\text{freq}}^\top \in \mathbb{R}^{B \times 62 \times 5}$ 。这一操作确保每行对应一个电极的全部 5 个频段值, 每列对应一个频段的全部 62 个通道值。

3.3 通道注意力模块

通道注意力模块的目标是学习 62 个电极对情绪识别的空间重要性权重。受 SE-Net [2] 启发, 采用 Squeeze-and-Excitation 结构:

1. **Squeeze**: 对每个电极的 5 个频段特征取均值, 得到全局描述向量 $\mathbf{z}_c \in \mathbb{R}^{B \times 62}$ 。
2. **Excitation**: 通过两层全连接网络学习电极间的交互关系:

$$\mathbf{a}_c = \sigma(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 \cdot \mathbf{z}_c + \mathbf{b}_1) + \mathbf{b}_2) \quad (2)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{15 \times 62}$ (降维比为 1/4), $\mathbf{W}_2 \in \mathbb{R}^{62 \times 15}$, σ 为 Sigmoid 函数。

3.4 频段注意力模块

频段注意力模块采用与通道注意力类似的结构, 但作用于频段维度:

1. **Squeeze**: 对每个频段的 62 个通道值取均值, 得到 $\mathbf{z}_f \in \mathbb{R}^{B \times 5}$ 。
2. **Excitation**: $\mathbf{a}_f = \sigma(\mathbf{W}_4 \cdot \text{ReLU}(\mathbf{W}_3 \cdot \mathbf{z}_f + \mathbf{b}_3) + \mathbf{b}_4)$, 其中 $\mathbf{W}_3 \in \mathbb{R}^{10 \times 5}$, $\mathbf{W}_4 \in \mathbb{R}^{5 \times 10}$ 。

3.5 注意力融合与分类

两种注意力通过可学习的缩放因子 α 和 β (均初始化为 0) 进行融合:

$$\tilde{\mathbf{X}} = \mathbf{X}_{\text{ch}} \odot (1 + \alpha \cdot \mathbf{a}_c + \beta \cdot \mathbf{a}_f) \quad (3)$$

其中 $\odot$ 表示逐元素乘法, $\mathbf{a}_c$ 和 $\mathbf{a}_f$ 分别通过广播机制扩展到 $(B, 62, 5)$ 形状。

该设计的核心优势在于: (1) **残差连接**: 1 确保即使注意力权重全为零, 原始特征仍能完整保留; (2) **渐进式注意力**: α 和 β 初始化为 0, 模型从纯 MLP 基线开始学习, 随着训练推进逐步激活注意力机制; (3) **双重互补**: 通道注意力捕捉空间维度的重要性 (哪个脑区), 频段注意力捕捉频谱维度的重要性 (哪个频段), 两者互补。

加权后的特征展平为 $(B, 310)$, 送入轻量级 MLP 分类器: $310 \rightarrow 64 \rightarrow 32 \rightarrow 3$, 每层后接 BatchNorm、ReLU 和 Dropout ($p = 0.6$)。模型总参数量约为 24,329。

3.6 训练策略

- **损失函数**: 交叉熵损失 (Cross-Entropy Loss)。
- **优化器**: AdamW, 学习率 5×10^{-4} , 权重衰减 5×10^{-3} 。
- **学习率调度**: 余弦退火 (Cosine Annealing), $T_{\max} = 100$ 。
- **MixUp 数据增强** [3]: 对训练样本进行凸组合增强, 混合参数 $\alpha_{\text{mix}} = 0.3$, 增强训练数据的多样性, 防止过拟合。
- **批次大小**: 128。
- **训练轮数**: 主实验 100 epochs, 消融实验 80 epochs。
- **最佳模型选择**: 每个 fold 记录验证集上准确率最高的模型状态 (DeepCopy state_dict), 最终用最佳模型收集预测结果。

4 实验设置

4.1 实验环境

实验在配备 NVIDIA GPU 的 Linux 服务器上进行, 具体环境如下:

- 操作系统: Ubuntu 22.04
- Python 版本: 3.10
- PyTorch 版本: 2.x (CUDA 支持)
- 其他依赖: numpy, scikit-learn, matplotlib

4.2 基线方法

为验证注意力机制的有效性, 设计了三种消融变体和基线模型, 所有模型共享相同的分类器架构 ($310 \rightarrow 64 \rightarrow 32 \rightarrow 3$, Dropout=0.6):

1. **Baseline (Pure MLP)**: 无注意力机制, 仅使用 MLP 分类器。
2. **Channel Attention Only**: 仅保留通道注意力模块。
3. **Frequency Attention Only**: 仅保留频段注意力模块。
4. **Dual Attention (Full)**: 完整的双注意力模型。

4.3 评估指标

采用以下指标评估模型性能:

- **准确率 (Accuracy)**: 12 折 LOSO 的平均准确率 $\pm$ 标准差。
- **混淆矩阵 (Confusion Matrix)**: 三类情绪的详细分类结果。
- **精确率 (Precision) / 召回率 (Recall) / F1 分数**: 各类别的分类性能。
- **注意力权重分布**: 通道注意力的脑地形图和频段注意力的柱状图。

5 实验结果

5.1 LOSO 交叉验证结果

双注意力模型在 12 折 LOSO 交叉验证中的详细结果如表 1 所示。

表 1: LOSO 交叉验证逐被试准确率

测试被试	准确率	测试被试	准确率
1	78.46%	8	94.54%
2	79.73%	9	78.66%
3	77.99%	10	81.79%
4	77.67%	11	90.26%
5	84.20%	12	79.61%
—	—	13	69.04%
—	—	14	82.70%
平均准确率		81.22% $\pm$ 6.20%	

模型在所有 12 折上的平均准确率为 **81.22%**，标准差为 **6.20%**。表现最好的被试 8 达到了 94.54%，表明对于部分被试，模型能够非常准确地识别其情绪状态。表现相对较差的被试 13 (69.04%) 也远高于随机概率 (33.33%)，说明模型在所有被试上均学到了有效的情绪判别模式。

5.2 混淆矩阵分析




图 2: LOSO 逐被试准确率 (左) 与总体混淆矩阵 (右)

总体混淆矩阵显示 (图 2 右), 三类情绪的详细分类情况如下:

- Positive (积极): Precision = 0.781, Recall = 0.728, F1 = 0.754
- Negative (消极): Precision = 0.787, Recall = 0.785, F1 = 0.786
- Neutral (中性): Precision = 0.860, Recall = 0.919, F1 = 0.889

Neutral 情绪的识别效果最好 (F1 = 0.889), 积极和消极情绪的识别效果相当。从混淆模式来看, Positive 和 Negative 之间存在较多的相互误判 (Positive 被误判为 Negative 1784 次, Negative 被误判为 Positive 1502 次), 这与两类情绪在效价维度上的对立性和脑电模式的部分重叠有关。而 Neutral 相对容易被区分, 与 Neutral 和 Non-Neutral 之间的较大差异相一致。

5.3 消融实验结果

消融实验的结果如表 2 所示, 所有模型均使用相同的预处理、训练超参数和评估协议 (LOSO, 80 epochs)。

表 2: 消融实验结果对比

模型	准确率	标准差
Baseline (Pure MLP)	78.58%	$\pm 7.25\%$
Channel Attention Only	77.18%	$\pm 7.44\%$
Frequency Attention Only	77.27%	$\pm 8.18\%$
Dual Attention	80.52%	$\pm 5.90\%$

消融实验揭示了几个重要发现:

1. **单一注意力不如不加**: Channel Only (77.18%) 和 Frequency Only (77.27%) 的准确率均低于 Pure MLP 基线 (78.58%)。这说明在跨被试设定下, 仅关注单一维度(空间或频率) 会过度约束模型, 反而损害泛化能力。
2. **双注意力互补有效**: Dual Attention (80.52%) 比基线提升了约 2 个百分点, 表明通道和频段注意力同时存在时能够互补——通道注意力识别关键脑区, 频段注意力识别关键频率成分, 两者协同才能完整捕捉情绪模式。
3. **注意力降低方差**: Dual Attention 的标准差最小 ($\pm 5.90\%$), 说明注意力机制有助于在不同被试间实现更稳定的泛化。

5.4 关键电极分析

将 12 个 LOSO fold 的通道注意力权重取平均, 得到各电极对情绪识别的平均贡献。Top-10 关键电极如表 3 所示, 平均脑地形图见图 3。

表 3: Top-10 关键电极 (按平均注意力权重排序)

排名	电极	脑区	注意力权重
1	F1	额叶左侧	0.5830
2	POz	顶枕中线	0.5784
3	Fp1	前额左侧	0.5718
4	F7	额叶左侧	0.5691
5	P1	顶叶左侧	0.5689
6	AF3	前额左侧	0.5582
7	O1	枕叶左侧	0.5566
8	CP3	中央顶左侧	0.5563
9	FCz	额中央中线	0.5554
10	CPz	中央顶中线	0.5551




图 3: 平均通道注意力脑地形图（左）与平均频段注意力柱状图（右）

从图 3 左图和表 3 可以看出，注意力权重最高的电极主要集中在前额叶（Fp1, AF3, F1, F7）和枕顶叶（POz, O1, P1）两个区域。这一发现与神经科学的已有认知高度一致：

- **前额叶**是情绪调节和认知评估的核心脑区，参与对情绪刺激的意义评估和情绪反应的调控。
- **枕叶**是视觉信息处理的初级皮层，在本实验中负责处理来自电影片段的视觉情绪刺激。
- 注意力权重分布呈现**左侧偏侧化**趋势（Top-10 中多为左侧电极），与情绪处理的效价假说（valence hypothesis）中左半球参与积极情绪处理的结论相符。

5.5 关键频段分析

从图 3 右图可以看出，各频段的平均注意力权重排序为：

$$\beta (0.5498) > \gamma (0.5304) > \delta (0.5102) \approx \theta (0.5099) > \alpha (0.4934) \quad (4)$$

高频段（ β , γ ）获得了更高的注意力权重，这与 Zheng 和 Lu [1] 的发现一致—— β 和 γ 频段在情绪识别中包含更丰富的信息。 α 频段的注意力权重最低，这可能是因为 α 波主要与放松和闭眼状态相关，在本实验的主动观影任务中表征能力较弱。

6 分析与讨论

6.1 跨被试泛化的关键因素

本实验从最初的近随机水平（约 34%）提升至 81.22% 的过程中，最关键的改进是**逐被试 z-score 标准化**和**MixUp 数据增强**。消融实验表明，即使不使用任何注意力机制，Pure MLP 基线在同样的预处理和增强策略下也能达到 78.58%，远超随机水平。

这一发现凸显了跨被试脑电情绪识别中的一个核心原则：**消除个体差异比设计复杂模型更重要**。逐被试标准化将每个被试的特征对齐到相同的分布（均值 0，标准差 1），使得模型能够学习跨被试共享的情绪模式，而非被试特异性模式。

6.2 注意力机制的贡献

虽然双注意力相比纯 MLP 的绝对提升幅度有限（约 2–3 个百分点），但其贡献不可忽视：

1. 注意力机制提供了**可解释性**——通过分析注意力权重的分布，可以识别哪些脑区和频段对情绪识别最重要，这是纯 MLP 无法提供的。
2. 注意力机制显著**降低了跨被试方差**（标准差从 $\pm 7.25\%$ 降至 $\pm 5.90\%$ ），表明它帮助模型找到了更稳定的、被试间共享的情绪特征。
3. 单一注意力表现不如基线、但组合后超越基线这一现象，说明通道和频段两个维度的信息在情绪识别中具有**互补性**。

6.3 个体差异分析

从逐被试准确率来看，不同被试之间的表现差异较大（69.04%–94.54%）。这反映了脑电情绪识别中的一个普遍现象：部分被试的脑电信号具有更稳定、更可区分的情绪模式，而另一些被试的信号噪声较大或情绪诱发效果较弱。未来的改进方向可以包括针对难分类被试的自适应策略或域适应方法。

6.4 与已有工作的对比

本研究 with SEED 数据集上的经典工作 [1] 有以下几个主要区别：

- **评估设定**：本文采用 LOSO 跨被试评估，而 Zheng 和 Lu 采用 subject-dependent 设定（每个被试独立训练测试）。跨被试设定更贴近实际应用场景，也更具挑战性。
- **模型方法**：本文使用轻量级注意力机制进行关键电极/频段探索，而原论文使用 DNN 分析逐电极/逐频段的分类贡献。
- **预处理策略**：本文提出了逐被试标准化 + MixUp 的组合策略，有效缓解了跨被试过拟合问题。

7 总结

本文基于 SEED 数据集，提出了一种轻量级双注意力神经网络模型，用于跨被试脑电情绪识别和关键电极/频段探索。主要贡献和结论如下：

1. **模型设计**: 提出了结合通道注意力和频段注意力的轻量级双注意力模型 (总参数量约 24K), 引入可学习的注意力缩放因子和残差连接, 使模型能够渐进地激活注意力机制。
2. **评估结果**: 在 12 折 LOSO 交叉验证中取得了 $81.22\% \pm 6.20\%$ 的平均准确率, 所有被试均显著高于随机水平。
3. **消融验证**: 消融实验表明双注意力机制相比纯 MLP 基线提升约 2.6 个百分点, 且标准差最小, 验证了双注意力设计的有效性。
4. **关键脑区发现**: 前额叶 (Fp1, AF3, F1) 和枕叶 (POz, O1) 对情绪识别的贡献最大, 与神经科学中情绪处理的前额-枕叶网络一致。
5. **关键频段发现**: β 和 γ 高频段获得最高的注意力权重, 体现了高频脑电成分在情绪识别中的重要性。
6. **方法启示**: 逐被试标准化是跨被试脑电分析的关键预处理步骤, 消除个体差异比设计复杂模型更重要。

未来的研究方向包括: (1) 探索更先进的域适应和域泛化方法, 进一步提升跨被试性能; (2) 融合眼动等多模态数据, 提升情绪识别的准确性和鲁棒性; (3) 将注意力分析结果应用于实际的脑机接口系统, 实现更高效的电极选择。

参考文献

- [1] W.-L. Zheng and B.-L. Lu, "Investigating critical frequency bands and channels for EEG-based emotion recognition with deep neural networks," *IEEE Transactions on Autonomous Mental Development*, vol. 7, no. 3, pp. 162–175, 2015.
- [2] J. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 7132–7141.
- [3] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, "mixup: Beyond empirical risk minimization," in *International Conference on Learning Representations (ICLR)*, 2018.
- [4] BCMI Laboratory, Shanghai Jiao Tong University, "SEED Dataset," <https://bcmi.sjtu.edu.cn/home/seed/>.
- [5] H. Zhang, M. Liu, C. Cai, Y. Li, and B.-L. Lu, "TorchEEG: A library for EEG-based emotion recognition," <https://torcheeg.readthedocs.io/>.

- [6] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.

附录：成员贡献说明

成员	具体贡献
成员 1	(请填写：数据处理、模型实现、实验设计等)
成员 2	(请填写)
成员 3	(请填写)
成员 4	(请填写)

附录：代码运行说明

完整代码已提交至 GitHub 仓库，目录结构如下：

```
seed/
  config.py          # 超参数配置
  data_loader.py     # 数据读取与逐被试标准化
  models.py          # 模型定义（双注意力 + 消融变体）
  trainer.py         # 训练/评估/LOSO/消融
  visualize.py       # 可视化（脑地形图、混淆矩阵等）
  main.py            # 主入口：python main.py
  requirements.txt   # 依赖：numpy, sklearn, torch, matplotlib
  README.md          # 详细运行说明
```

运行命令：

```
cd seed
pip install -r requirements.txt
python main.py
```